UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
INSTITUTO DE INFORMÁTICA
CURSO DE CIÊNCIA DA COMPUTAÇÃO

EDUARDO ANDRÉ LEITE

Desempenho e Expressividade da função de ativação PReLU em Modelos Neurais

Monografia apresentada como requisito parcial para a obtenção do grau de Bacharel em Ciência da Computação

Orientador: Prof. Dr. Anderson Tavares
Co-orientador: Prof. Dr. Rafael Pinto

Porto Alegre
2025

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
Reitora: Profª. Marcia Cristina Bernardes Barbosa
Vice-Reitora: Prof. Pedro de Almeida Costa
Pró-Reitora de Graduação: Profª. Nádya Pesce da Silveira
Diretor do Instituto de Informática: Prof. Luciano Paschoal Gaspary
Coordenador do Curso de Ciência de Computação: Prof. Marcelo Walter
Bibliotecário-chefe do Instituto de Informática: Alexsander Borges Ribeiro

RESUMO

Este estudo investiga a eficiência e expressividade da função de ativação *PReLU (Parametric Rectified Linear Unit)* em redes neurais profundas, com foco em sua capacidade de substituir outras funções amplamente utilizadas, como ReLU, Tanh e Abs. A PReLU, uma extensão da ReLU, destaca-se por introduzir um parâmetro adaptável que resolve limitações como o problema de unidades mortas, além de ser capaz de assumir a forma de outras funções de ativação.

A pesquisa parte da hipótese de que essa flexibilidade pode oferecer vantagens práticas em tarefas complexas, como maior acurácia e/ou aprendizado mais eficiente. Para avaliar essas hipóteses, foram realizados experimentos com arquiteturas consagradas, como LeNet e RDNet, utilizando *datasets* de classificação de imagens amplamente reconhecidos, como MNIST, FashionMNIST e CIFAR-10.

Os resultados indicam que a PReLU apresenta um desempenho competitivo em relação às demais funções, frequentemente apresentando valores de acurácia superiores. Estes achados reforçam seu potencial como uma solução simples e versátil para problemas de classificação de imagens em redes neurais.

Palavras-chave: PReLU. Redes neurais profundas. Funções de ativação. Otimização de redes neurais.

Performance and Expressiveness of the PReLU Activation Function in Neural Networks:

ABSTRACT

This study investigates the efficiency and expressiveness of the Parametric Rectified Linear Unit (PReLU) activation function in deep neural networks, focusing on its ability to replace other widely used functions such as ReLU, Tanh, and Abs. PReLU, an extension of ReLU, introduces a learnable parameter that addresses limitations such as the dying neuron problem while also being capable of assuming the shape of other activation functions.

The research hypothesizes that this flexibility can offer practical advantages in complex tasks, such as improved accuracy and/or more efficient learning. To evaluate these hypotheses, experiments were conducted with established architectures, including LeNet and RDNet, using well-known datasets such as MNIST, FashionMNIST, and CIFAR-10.

The results indicate that PReLU not only achieves competitive performance but also reduces the need for neurons in certain scenarios, contributing to the development of more compact and expressive models. These findings reinforce its potential as a simple and versatile solution for activation function challenges in neural networks.

Keywords: PReLU. Deep neural networks. Activation functions. Neural network optimization.

LISTA DE FIGURAS

Figura 2.1 Comparações das Funções de Ativação 14

Figura 4.1 Arquitetura da Rede LeNet 19
Figura 4.2 Arquitetura da Rede RDNet 20

Figura 6.1 Médias de Acurácia e Erro Padrão das Funções de Ativação utilizando LeNet-5 no dataset MNIST 26
Figura 6.2 Médias de Acurácia e Erro Padrão das Funções de Ativação utilizando LeNet-5 no dataset FashionMNIST 28
Figura 6.3 Médias de Acurácia e Erro Padrão das Funções de Ativação utilizando LeNet-5 no dataset CIFAR-10 29
Figura 6.4 Médias de Acurácia e Erro Padrão das Funções de Ativação utilizando RDNet-L no dataset CIFAR-10 30

LISTA DE TABELAS

Tabela 6.1 Médias de Acurácia das Funções de Ativação utilizando LeNet-5 no dataset MNIST. Valores em negrito são os melhores por época, enquanto valores em vermelho são estatisticamente diferentes do melhor e em azul são estatisticamente semelhantes ao melhor em cada época. Valores-p são apresentados no Apêndice A.1). 27
Tabela 6.2 Médias de Acurácia das Funções de Ativação utilizando LeNet-5 no dataset FashionMNIST. Valores em negrito são os melhores por época, enquanto valores em vermelho são estatisticamente diferentes do melhor e em azul são estatisticamente semelhantes ao melhor em cada época. Valores-p são apresentados no Apêndice A.2)..... 28
Tabela 6.3 Médias de Acurácia das Funções de Ativação utilizando LeNet-5 no dataset CIFAR-10. Valores em negrito são os melhores por época, enquanto valores em vermelho são estatisticamente diferentes do melhor e em azul são estatisticamente semelhantes ao melhor em cada época. Valores-p são apresentados no Apêndice A.3)..... 29
Tabela 6.4 Médias de Acurácia das Funções de Ativação utilizando RDNet-L no dataset CIFAR-10. Valores em negrito são os melhores por época, enquanto valores em vermelho são estatisticamente diferentes do melhor e em azul são estatisticamente semelhantes ao melhor em cada época. Valores-p são apresentados no Apêndice A.4)..... 31
Tabela 6.5 Médias de Runtimes das Funções de Ativação utilizando RDNet-L no dataset CIFAR-10..... 31

LISTA DE ABREVIATURAS E SIGLAS

PReLU	Parametric Rectified Linear Unit
CR	Um parâmetro por camada e inicialização aleatória do **a**
C0	Um parâmetro por camada e **a** inicializado com valor 0
NR	Um parâmetro por neurônio e inicialização aleatória do **a**
N0	Um parâmetro por neurônio e **a** inicializado com valor 0
ReLU	Rectified Linear Unit
a	Parâmetro treinável da PReLU
Tanh	Hyperbolic Tangent
Abs	Absolute Value
LeNet	LeCun Network
RDNet	DenseNets Reloaded
MLP	Multi-Layer Perceptron
GCU	Growing Cosine Unit
ViT	Vision Transformer

SUMÁRIO

1 INTRODUÇÃO 9
1.1 Funções de Ativação e o Problema do XOR: Implicações para a PReLU 9
2 FUNDAMENTAÇÃO TEÓRICA 11
2.1 ReLU e o Problema dos Neurônios Mortos 11
2.2 Leaky ReLU como Alternativa 12
2.3 PReLU: Uma Abordagem Paramétrica 12
2.4 Abs: Função Absoluta 13
2.5 Equivalências da PReLU com Outras Funções 13
3 TRABALHOS RELACIONADOS 15
4 METODOLOGIA 17
4.1 Datasets Utilizados 17
4.2 Arquiteturas Utilizadas 18
5 EXPERIMENTOS 21
5.1 Preparação dos Dados 21
5.2 Modelos Implementados 22
5.3 Treinamento dos Modelos 22
5.4 Avaliação e Métricas 23
5.5 Funções de Ativação Comparadas 23
5.6 Execução e Coleta de Resultados 24
5.7 Validação dos Resultados 24
6 RESULTADOS 25
6.1 Resultados com LeNet-5 26
6.1.1 Resultados com LeNet-5 no Dataset MNIST 26
6.1.2 Resultados com LeNet-5 no Dataset FashionMNIST 28
6.1.3 Resultados com LeNet-5 no Dataset CIFAR 29
6.2 Análise Geral da LeNet-5 30
6.3 Resultados com RDNet-L 30
7 CONCLUSÃO 32
7.1 Limitações e Ameaças à Validade 32
7.2 Trabalhos Futuros 33
REFERÊNCIAS 35
APÊNDICE A — VALORES-P DOS TESTES T DE STUDENT 37
A.1 Testes t de Student com LeNet-5 no MNIST 37
A.2 Testes t de Student com LeNet-5 no FashionMNIST 38
A.3 Testes t de Student com LeNet-5 no CIFAR-10 39
A.4 Testes t de Student com LeNet-5 no CIFAR-10 40

1 INTRODUÇÃO

As redes neurais profundas desempenham um papel crucial em uma ampla gama de tarefas, desde reconhecimento de padrões até aprendizado por reforço. No entanto, muitas vezes a escolha das funções de ativação é negligenciada, e a *ReLU (Rectified Linear Unit)* é utilizada "por *default*"devido à sua simplicidade e eficiência computacional. Apesar disso, a escolha apropriada da função de ativação tem um impacto significativo na expressividade e no desempenho desses modelos. Entre as funções mais utilizadas, a ReLU apresenta limitações conhecidas, como o problema dos neurônios mortos *(dying neuron problem)*, que motivaram a busca por alternativas mais robustas. Foi nesse cenário que surgiu a *PReLU (Parametric Rectified Linear Unit)*, uma variação que resolve esse problema ao introduzir um parâmetro ajustável, conferindo flexibilidade adicional ao modelo.

1.1 Funções de Ativação e o Problema do XOR: Implicações para a PReLU

O problema do *XOR (Exclusive OR)* tem sido um desafio histórico para redes neurais de camada única (MINSKY; PAPERT, 1988), tradicionalmente exigindo arquiteturas multicamadas (MLPs) devido à sua natureza não linear.

Em (PINTO; TAVARES, 2024), trabalho utilizado como base para este estudo, é demonstrado que a PReLU oferece uma solução eficiente para o XOR com apenas uma camada. A introdução de um parâmetro aprendível na PReLU confere a ela maior flexibilidade em comparação com a ReLU padrão. A capacidade de resolver o XOR com uma única camada indica que a PReLU possui:

- **Alta Capacidade de Modelagem Não-Linear:** A PReLU demonstra potencial para lidar com relações complexas entre entradas e saídas, transcendendo a separação linear.
- **Adaptabilidade:** O parâmetro aprendível permite que a função se ajuste dinamicamente aos dados durante o treinamento, o que é crucial para o XOR e vantajoso em outros problemas com distribuições complexas.
- **Potencial para Arquiteturas Mais Simples:** A solução do XOR com uma única camada sugere a possibilidade de reduzir a necessidade de camadas ocultas em algumas aplicações.

Pinto e Tavares também comparam a PReLU com a rede neural MLPs e a função de ativação GCU (*Growing Cosine Unit*), mostrando vantagens em taxa de aprendizado, convergência e número de parâmetros, o que motiva a investigação da *PReLU* em problemas mais complexos.

A PReLU, que generaliza outras funções como ReLU e Leaky ReLU através do parâmetro aprendível **"a"**, demonstra, através da solução do XOR, uma notável flexibilidade. Essa característica justifica a investigação do seu desempenho em tarefas de classificação de imagens, foco desta pesquisa.

O trabalho de Pinto e Tavares, (PINTO; TAVARES, 2024), demonstra a capacidade da PReLU de resolver o XOR com uma única camada, evidenciando seu potencial. A presente pesquisa complementa essa descoberta ao investigar o desempenho da PReLU em tarefas práticas de classificação de imagens, buscando validar suas vantagens teóricas em cenários mais desafiadores e comparando-a com outras funções relevantes.

2 FUNDAMENTAÇÃO TEÓRICA

Aprendizado de máquina (*Machine Learning*) é uma subárea da inteligência artificial que visa criar sistemas capazes de aprender e tomar decisões baseadas em dados. Dentro desse campo, as redes neurais artificiais se destacam como uma técnica popular, inspirada no funcionamento do cérebro humano. Redes neurais profundas (*Deep Neural Networks*) são compostas por múltiplas camadas de neurônios artificiais que processam e transformam dados em representações de maior nível de abstração, possibilitando avanços significativos em tarefas como reconhecimento de imagens, processamento de linguagem natural e outras.

Um dos componentes centrais em redes neurais é a função de ativação, que determina como os neurônios processam suas entradas e influenciam as saídas. De acordo com, (RAMACHANDRAN; ZOPH; LE, 2017), a escolha da função de ativação impacta diretamente a capacidade de aprendizado e o desempenho da rede. Dentre as funções de ativação mais populares, a ReLU (*Rectified Linear Unit*), introduzida formalmente no contexto de redes neurais por (NAIR; HINTON, 2010), destaca-se por sua simplicidade computacional e eficácia em resolver problemas como a dissipação de gradientes.

2.1 ReLU e o Problema dos Neurônios Mortos

A função de ativação ReLU é definida como:

$$f(x) = \max(0, x) \tag{2.1}$$

Ou seja, a função retorna zero para entradas negativas e a própria entrada para valores positivos. Essa simplicidade torna a ReLU altamente eficiente em termos computacionais, além de ajudar a acelerar o treinamento em redes profundas ao mitigar o problema de gradientes saturados.

No entanto, a ReLU apresenta uma limitação significativa conhecida como o problema dos neurônios mortos. Isso ocorre quando um neurônio recebe entradas que o mantêm constantemente na região negativa da função, fazendo com que o gradiente para aquele neurônio seja sempre zero. Como consequência, o neurônio para de atualizar seus pesos e deixa de contribuir para o aprendizado, afetando negativamente o desempenho da rede, como demonstrado em (AGARAP, 2019).

2.2 Leaky ReLU como Alternativa

Para mitigar o problema dos neurônios mortos, a Leaky ReLU, introduzida por (MAAS; HANNUN; NG, 2013), propôs uma modificação simples na fórmula da ReLU. A função é definida como:

$$f(x) = \begin{cases} x & \text{se } x > 0, \\ 0.01 \cdot x & \text{se } x \leq 0, \end{cases} \tag{2.2}$$

Ao introduzir uma inclinação fixa para a região negativa (geralmente 0.01), a Leaky ReLU permite que os gradientes continuem fluindo mesmo para entradas negativas, reduzindo a probabilidade de neurônios mortos. Apesar de sua eficácia, a inclinação fixa limita a flexibilidade da função, especialmente em problemas onde diferentes padrões de dados podem exigir comportamentos mais adaptáveis.

2.3 PReLU: Uma Abordagem Paramétrica

A PReLU (*Parametric Rectified Linear Unit*), proposta por (HE et al., 2015), é uma extensão direta da Leaky ReLU, onde a inclinação da parte negativa da função não é fixa, mas sim aprendida durante o treinamento. A função é definida como:

$$f(x) = \begin{cases} x & \text{se } x > 0, \\ a \cdot x & \text{se } x \leq 0, \end{cases} \tag{2.3}$$

onde a é um parâmetro ajustável, inicializado aleatoriamente e atualizado com os demais pesos da rede. Essa flexibilidade adicional permite que a PReLU se adapte melhor a padrões complexos nos dados, otimizando automaticamente a inclinação ideal para cada neurônio.

Diferentemente da ReLU, que define valores negativos como zero, e da Leaky ReLU, que utiliza uma inclinação fixa, a PReLU oferece maior expressividade e capacidade de aprendizado. Isso é especialmente útil em redes mais profundas ou em tarefas que exigem maior flexibilidade na modelagem.

2.4 Abs: Função Absoluta

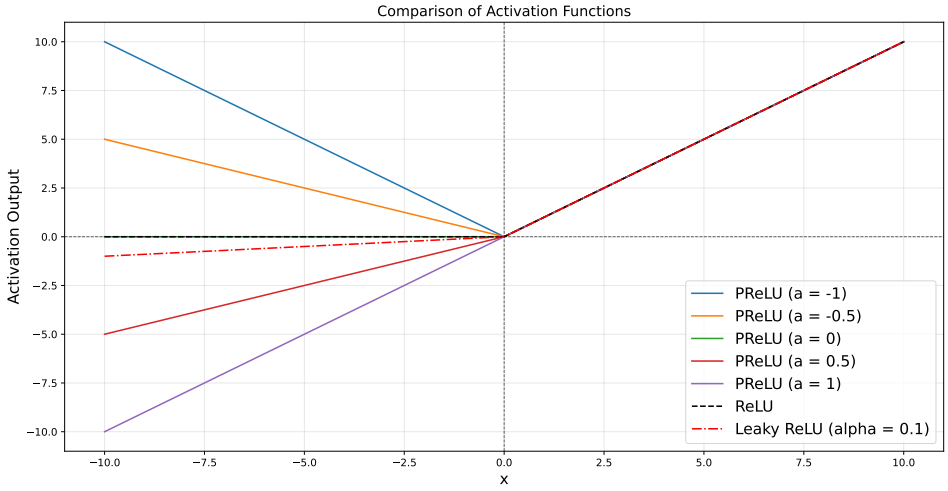
Além da PReLU, outra função que tem sido considerada em modelos de redes neurais é a função abs(x). Essa função, que retorna o valor absoluto da entrada, pode ser uma alternativa simples e eficiente para modelar relações não lineares. A função abs(x) é facilmente computável e pode representar algumas relações complexas de maneira eficaz, especialmente em problemas onde a simetria na entrada é importante. Em (BERNGARDT, 2023), foi demonstrada a eficácia da função abs(x) na mitigação de problemas de gradientes evanescentes e explosivos em redes profundas, além de apresentar resultados promissores na redução do número de parâmetros em arquiteturas *"LeNet-like"*. O uso de funções como abs(x), em conjunto com outras técnicas de regularização ou de otimização, pode ser uma maneira de simplificar o modelo sem sacrificar expressividade, embora sua capacidade de resolver problemas complexos ainda precise ser mais investigada em comparação com a PReLU e outras funções de ativação.

2.5 Equivalências da PReLU com Outras Funções

A ReLU é reconhecida por sua simplicidade e eficiência computacional, características que a tornam adequada para uma ampla gama de problemas. No entanto, o problema dos neurônios mortos limita sua capacidade em redes mais profundas ou em problemas com alta variabilidade nos dados. A Leaky ReLU, por sua vez, aborda essa limitação ao introduzir uma inclinação fixa na região negativa, garantindo um fluxo constante de gradientes. No entanto, sua falta de adaptabilidade em relação à inclinação reduz sua flexibilidade para modelar dados mais complexos.

A PReLU avança nessa questão ao tornar a inclinação da região negativa ajustável durante o treinamento, aumentando sua expressividade e capacidade de adaptação a padrões complexos. Essa característica permite que a PReLU seja equivalente à ReLU (quando $a = 0$) ou à Leaky ReLU (quando a assume um valor fixo maior que zero). Além disso, dependendo dos valores aprendidos por a, a PReLU pode se comportar de maneira semelhante a abs(x) (quando $a = -1$), uma função que reflete os valores negativos no eixo positivo. Essa equivalência sugere que a PReLU pode, em tese, reproduzir o comportamento de outras funções de ativação e até superar suas limitações em certos contextos. Essas equivalências podem ser demonstradas de acordo com a figura: 2.1.

Figura 2.1: Comparações das Funções de Ativação



Fonte: O Autor

A relação entre essas funções de ativação — ReLU, PReLU e abs(x) — é crucial para determinar qual delas pode ser mais adequada para diferentes tipos de problemas, especialmente em tarefas de classificação de imagens. Embora a PReLU tenha mostrado desempenho superior em algumas situações, sua complexidade adicional pode ser um fator limitante, especialmente em datasets ou modelos menores. Além disso, a necessidade de ajustar o parâmetro a pode introduzir um risco de *overfitting*, o que exige uma análise cuidadosa durante o treinamento.

A literatura atual ainda apresenta uma lacuna em relação ao desempenho comparativo da PReLU e outras funções de ativação não tradicionais, como abs(x), em contextos específicos de identificação de imagens. Por isso, esta pesquisa se propõe a explorar essas alternativas, avaliando sua capacidade de resolver problemas complexos com menos neurônios e comparando seu desempenho em cenários práticos de classificação de imagens.

3 TRABALHOS RELACIONADOS

Esta seção revisa trabalhos relevantes sobre funções de ativação em redes neurais, com foco na PReLU (*Parametric Rectified Linear Unit*) e sua aplicação em problemas complexos.

***THREE DECADES OF ACTIVATIONS: A COMPREHENSIVE SURVEY OF 400 ACTIVATION FUNCTIONS FOR NEURAL NETWORKS* (KUNC; KLéMA, 2024):**

Esse artigo realiza uma análise abrangente sobre as funções de ativação, que são fundamentais para o sucesso das redes neurais ao introduzirem não-linearidade nos modelos. O texto destaca a falta de uma fonte completa e organizada que reúna todas as funções de ativação existentes, o que pode levar à redundância e à redescoberta de funções já propostas. Para preencher essa lacuna, os autores apresentam um levantamento envolvendo 400 funções de ativação, fornecendo uma visão sistemática e extensa com referências às suas fontes originais. O objetivo principal é oferecer a visão mais abrangente já feita sobre essas funções, enquanto o objetivo secundário é atualizar o entendimento atual sobre o tema.

O artigo se relaciona diretamente com meu trabalho, pois realiza uma análise sistemática das funções de ativação que serão utilizadas em meus experimentos, servindo de base para situar a PReLU em um contexto mais amplo, comparando-a com outras funções já propostas e avaliando como ela se destaca em termos de expressividade, eficiência e aplicabilidade em tarefas como classificação de imagens.

***Improving Classification Neural Networks by using Absolute activation function (MNIST/LeNet-5 example)*(BERNGARDT, 2023)**:

Este artigo investiga o uso da função de ativação *Absolute* (abs(x)) em redes neurais voltadas para classificação, demonstrando sua eficácia em problemas simples e complexos. Utilizando a rede LeNet-5 como base para resolver o problema MNIST, os autores comparam o desempenho da função abs(x) com outras funções de ativação populares, como Tanh, ReLU e SeLU. Os resultados mostram que a abs(x) evita problemas de gradientes desaparecendo ou explodindo, tornando-se adequada tanto para redes simples quanto profundas. Os autores também abordam a alta volatilidade do treinamento com abs(x), propondo uma modificação do algoritmo de treinamento ADAM. Essa adaptação inclui estimar um limite inferior da acurácia em qualquer conjunto de teste usando análises do conjunto de validação em cada época de treinamento. Além disso, o algoritmo ajusta a taxa de aprendizado e reconfigura o ADAM conforme necessário. Essa abor-

dagem permitiu, nos experimentos, reduzir significativamente o número de parâmetros treináveis na rede neural, ao mesmo tempo em que melhorava a acurácia preditiva.

Os resultados positivos alcançados pela função $\mathrm{Abs}(x)$ sugerem que a PReLU também pode atingir valores superiores, especialmente considerando que, quando configurada com $a = -1$, ela se torna equivalente à $\mathrm{Abs}(x)$, uma vez que ambas compartilham a característica central de refletir valores negativos no eixo positivo. Isso indica que a PReLU, nesse caso, pode alcançar resultados igualmente robustos, combinando a expressividade adicional proporcionada pela parametrização com a eficiência observada na $\mathrm{Abs}(x)$. Ademais, a capacidade de reduzir o número de parâmetros da rede sem comprometer a acurácia está alinhada com o foco do meu trabalho, que busca explorar a eficiência e a expressividade das funções de ativação.

4 METODOLOGIA

Esta pesquisa investigou o impacto de diferentes funções de ativação, incluindo variações da PReLU, além de ReLU, Leaky ReLU, Tanh, Tanh do LeCun e Abs, em redes neurais profundas. Foram implementados experimentos baseados em treinamento supervisionado para avaliar o desempenho dessas funções. Os *datasets* utilizados foram CIFAR-10, MNIST e FashionMNIST, amplamente reconhecidos na literatura por sua relevância em tarefas de classificação de imagens. A seguir, descrevem-se as principais etapas da metodologia.

Os *datasets* CIFAR-10, MNIST e FashionMNIST foram selecionados por sua popularidade e adequação a tarefas de classificação de imagens. As funções de ativação escolhidas incluem variantes conhecidas e experimentais, permitindo uma análise comparativa abrangente. Dois modelos principais foram definidos para os experimentos: LeNet e RDNet, com adaptações para incluir diferentes funções de ativação.

O planejamento incluiu a definição de métricas de desempenho, configuração dos experimentos e critérios para avaliação estatística. A seguir, detalha-se o desenvolvimento prático desta pesquisa.

Este capítulo apresenta os experimentos realizados para avaliar o impacto das funções de ativação, com foco em sua eficácia e expressividade em diferentes cenários. A escolha dos *datasets* — MNIST, FashionMNIST e CIFAR-10 — reflete a preocupação em abranger desde problemas simples até desafios mais complexos, permitindo explorar a capacidade das funções de ativação em diferentes níveis de abstração. As arquiteturas selecionadas, LeNet e RDNet, foram utilizadas para testar a eficácia das funções em redes neurais com distintas complexidades estruturais, balanceando simplicidade e sofisticação.

Com essa abordagem, os experimentos visam compreender como a PReLU, em comparação com alternativas como Tanh, ReLU e Abs, impacta o desempenho em tarefas de classificação de imagens, desde problemas básicos até cenários mais desafiadores e realistas. Os resultados obtidos servirão como base para discutir as vantagens e limitações dessas funções de ativação em redes profundas.

4.1 Datasets Utilizados

Para a avaliação prática das funções de ativação investigadas, foram escolhidos datasets reconhecidos e frequentemente adotados na área de aprendizado de máquina,

devido à sua popularidade como benchmarks em tarefas de classificação de imagens.

MNIST (*Modified National Institute of Standards and Technology Database*): O MNIST é um dos *datasets* mais conhecidos e utilizados no treinamento e avaliação de modelos de aprendizado profundo, contendo 60.000 imagens de treino e 10.000 de teste monocromáticas, cada uma com resolução de 28×28 pixels com valor de intensidade entre 0 (preto) e 255 (branco). Consiste em 10 classes de dígitos manuscritos (0 a 9). Sua simplicidade o torna ideal para validar conceitos fundamentais e testar funções de ativação, como a ReLU e a PReLU (LECUN et al., 1998).

FashionMNIST: Desenvolvido como uma alternativa mais desafiadora ao MNIST, o FashionMNIST também contém 60.000 imagens de treino e 10.000 de teste, também com resolução de 28×28 pixels com valor de intensidade entre 0 (preto) e 255 (branco). Consiste em 10 classes de diferentes categorias de roupas e acessórios de moda. Apesar de compartilhar o mesmo formato do MNIST, a complexidade visual dos itens faz com que ele seja mais adequado para testar a capacidade de modelos de capturar padrões visuais mais detalhados (XIAO; RASUL; VOLLGRAF, 2017).

CIFAR-10: O CIFAR-10 é um *dataset* mais complexo, contendo 50.000 imagens de treino e 10.000 de teste, cada uma com resolução de 32×32 pixels com valor de intensidade entre 0 e 255 para cada canal (RGB). Consiste em 10 classes representando diferentes categorias, como aviões, carros, animais e objetos. Ele é amplamente empregado para testar a eficácia de arquiteturas mais sofisticadas e a capacidade das funções de ativação em lidar com dados mais variados e detalhados. (KRIZHEVSKY; HINTON, 2009)

Esses datasets oferecem diferentes níveis de complexidade, o que permite avaliar não apenas a eficácia das funções de ativação, mas também sua expressividade em cenários com variação crescente de padrões visuais. A combinação desses benchmarks proporciona uma análise abrangente do desempenho das funções estudadas em tarefas de classificação de imagens, desde problemas relativamente simples (MNIST) até desafios mais complexos e realistas (CIFAR-10). Por serem referência na comunidade, seus resultados permitem uma comparação direta com trabalhos anteriores.

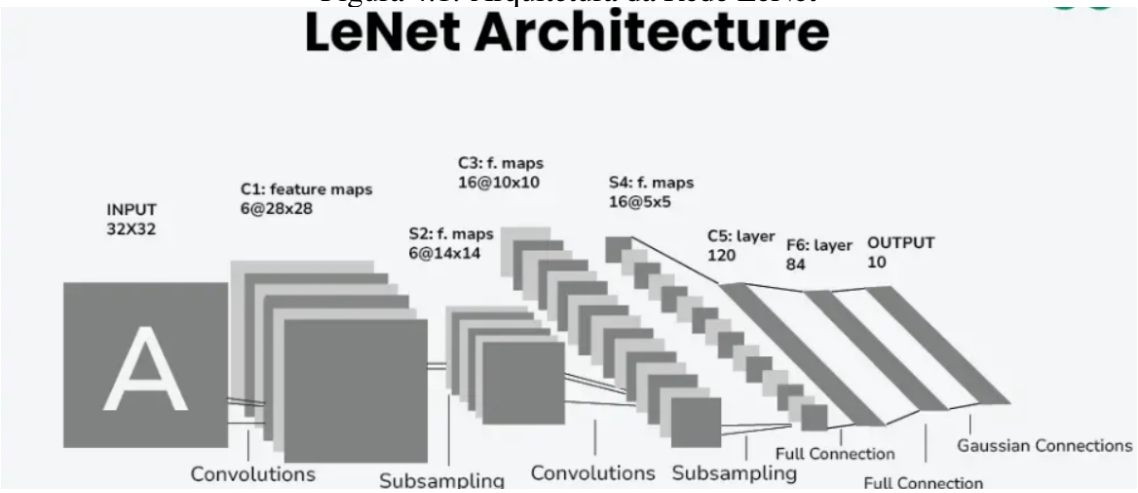
4.2 Arquiteturas Utilizadas

Para avaliar o impacto das funções de ativação nos modelos neurais, foram selecionadas duas arquiteturas bem estabelecidas no campo do aprendizado profundo: a LeNet

e a RDNet. Essas arquiteturas foram escolhidas devido à sua relevância histórica e capacidade de lidar com diferentes níveis de complexidade em tarefas de classificação de imagens.

LeNet: A LeNet, foi uma das primeiras redes neurais convolucionais aplicadas com sucesso em problemas reais, proposta por (LECUN et al., 1989). Originalmente projetada para a classificação de dígitos manuscritos no dataset MNIST, a arquitetura consiste em uma combinação de camadas convolucionais, *pooling* e densamente conectadas. Sua simplicidade torna-a uma excelente escolha para explorar a influência de funções de ativação em redes com poucos parâmetros, permitindo um foco maior na análise de expressividade e eficiência.

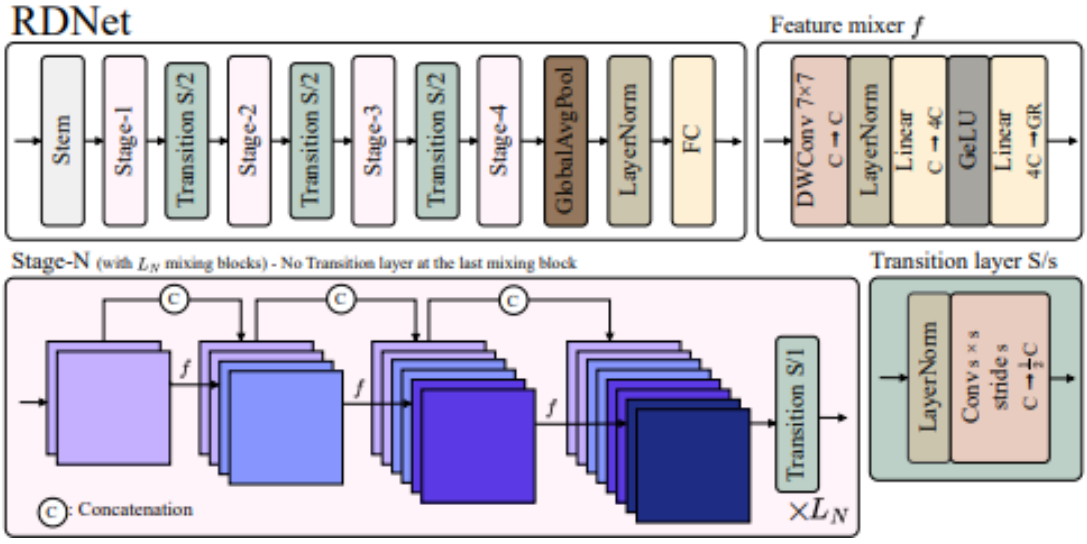
Figura 4.1: Arquitetura da Rede LeNet



Fonte: (LECUN et al., 1998)

RDNet: A RDNet *(Reduced-Dimensionality Network)*, introduzida por (SHANG et al., 2022) é uma arquitetura mais recente, projetada para tarefas de classificação com datasets mais complexos, como o CIFAR-10. Sua estrutura incorpora técnicas modernas de regularização e camadas projetadas para reduzir a dimensionalidade enquanto mantém alta capacidade de representação. Essa arquitetura foi escolhida para avaliar o desempenho das funções de ativação em redes com maior número de parâmetros e maior capacidade de modelagem, testando sua eficácia em capturar padrões mais complexos.

Figura 4.2: Arquitetura da Rede RDNet



Fonte: (KIM; HEO; HAN, 2024)

Ambas as arquiteturas oferecem um equilíbrio entre simplicidade e complexidade, permitindo avaliar a PReLU e suas alternativas em cenários variados. A LeNet fornece uma base sólida para entender o comportamento em redes menores, enquanto a RDNet-L apresenta desafios mais avançados, possibilitando uma análise abrangente da robustez e eficiência das funções de ativação.

5 EXPERIMENTOS

Neste capítulo, descrevo as etapas realizadas para implementar e conduzir os experimentos propostos, desde a preparação dos dados até a coleta dos resultados. O objetivo principal foi criar um ambiente experimental sólido que permitisse avaliar o impacto de diferentes funções de ativação em arquiteturas neurais, utilizando benchmarks reconhecidos.

Os dados foram processados e normalizados de acordo com as especificidades de cada *dataset*, garantindo compatibilidade com os modelos implementados. As arquiteturas selecionadas, LeNet-5 e RDNet-L, foram ajustadas para incluir diversas funções de ativação, possibilitando comparações detalhadas em diferentes cenários. Durante o treinamento, foram aplicadas técnicas modernas, como *gradient accumulation* e AMP (*Automatic Mixed Precision*), além de configurar uma semente global para assegurar reprodutibilidade.

As avaliações utilizaram métricas consolidadas, como acurácia média e erro padrão, complementadas por análises estatísticas. Com essa abordagem, este capítulo apresenta um relato detalhado do desenvolvimento experimental, garantindo que os resultados obtidos possam ser replicados e comparados com estudos semelhantes na área de aprendizado profundo.

5.1 Preparação dos Dados

Os datasets foram carregados utilizando a biblioteca *PyTorch*, com preprocessamento padronizado para garantir a normalização dos valores de entrada. Para CIFAR-10, aplicaram-se normalizações baseadas nas médias e desvios padrão dos canais de cor, enquanto MNIST e FashionMNIST, sendo *datasets* em escala de cinza, foram apenas escalados para valores entre 0 e 1. Os *loaders* de dados foram configurados com tamanhos de *batch* adaptados às limitações do *hardware*. Para as arquiteturas baseadas na LeNet, utilizou-se um *batch size* de 256 para treino e 1000 para teste. Já para a RDNet, devido a limitações de memória da GPU, os tamanhos de *batch* foram reduzidos para 8 no treino e 100 no teste. Essa configuração assegurou a execução eficiente dos experimentos, mesmo em cenários de maior demanda computacional.

5.2 Modelos Implementados

Dois modelos principais foram implementados para os experimentos:

LeNet-5: A variante LeNet-5, arquitetura pioneira em redes neurais convolucionais proposta por (LECUN et al., 1995) para utilização no dataset MNIST, caracteriza-se por uma estrutura sequencial composta por camadas convolucionais, camadas de subamostragem (pooling) e camadas totalmente conectadas. Esta arquitetura, originalmente desenvolvida para reconhecimento de caracteres manuscritos, foi empregada neste trabalho para avaliar o desempenho das funções de ativação em redes de menor complexidade, utilizando os conjuntos de dados MNIST e FashionMNIST.

RDNet-L: A variante RDNet-Large (RDNet-L), proposta por (KIM; HEO; HAN, 2024), emprega blocos densamente conectados (*DenseStage*) e um componente inicial *PatchifyStem*, sendo destinada a tarefas de classificação mais complexas, como a classificação de imagens no conjunto de dados CIFAR-10. A seleção desta arquitetura justifica-se por apresentar os melhores resultados de acurácia no conjunto de dados CIFAR-10, entre os modelos avaliados que não requerem dados de treinamento adicionais, de acordo com o leaderboard (IMAGE...,). Sua elevada capacidade representacional, decorrente de sua maior profundidade, possibilita uma análise mais abrangente do impacto das funções de ativação.

Ambos os modelos foram adaptados para incluir as funções de ativação ReLU, PReLU, Tanh e Abs, facilitando comparações diretas.

5.3 Treinamento dos Modelos

O treinamento foi realizado utilizando a função de custo *CrossEntropyLoss* e o otimizador Adam, com uma taxa de aprendizado inicial de 0.0005. Para evitar problemas de instabilidade, foi empregada a técnica de *gradient accumulation* com 4 passos de acumulação. Além disso, utilizou-se a biblioteca AMP (*Automatic Mixed Precision*) para acelerar o treinamento em dispositivos com suporte a GPUs.

Cada modelo foi treinado por 20 épocas em cada configuração experimental. Para garantir reprodutibilidade, foi configurada uma semente global para todas as execuções (`set_seed()`).

5.4 Avaliação e Métricas

Ao final de cada treinamento, os modelos foram avaliados no conjunto de teste correspondente. A métrica principal utilizada foi a acurácia, calculada como a porcentagem de previsões corretas. Para cada configuração (modelo, função de ativação e dataset), foram realizadas 10 execuções independentes. Com isso, foram calculadas estatísticas descritivas, incluindo a média e o erro padrão da acurácia, permitindo uma análise mais robusta do desempenho dos modelos e das funções de ativação em diferentes cenários experimentais.

5.5 Funções de Ativação Comparadas

Os experimentos incluíram variações das funções de ativação nos modelos implementados. Em particular, foram avaliadas:

- **ReLU:** Função largamente empregada em redes convolucionais devido à sua eficiência computacional (NAIR; HINTON, 2010).
- **Leaky ReLU:** Variante da ReLU que permite um pequeno gradiente para valores negativos, reduzindo o risco de neurônios mortos (MAAS; HANNUN; NG, 2013).
- **PReLU com 1 parâmetro por camada:** Variante do ReLU que incorpora um parâmetro adaptável único por camada, configurado inicialmente com valor igual a zero **(P0)** ou com inicialização aleatória **(PR)**, a forma *default* da PReLU (HE et al., 2015).
- **PReLU com 1 parâmetro por neurônio:** Outra versão do PReLU, onde cada neurônio possui um parâmetro adaptável individual, configurado inicialmente com valor igual a zero **(N0)** ou com inicialização aleatória **(NR)** (HE et al., 2015).
- **Tanh:** Função clássica de ativação, reconhecida por sua não linearidade suave.
- **Tanh do LeCun:** Variante ajustada da função *Tanh*, que utiliza uma escala menor para melhorar a estabilidade da rede (LECUN, 1989).
- **Abs:** Função matemática experimental que aplica o valor absoluto da entrada, explorada como alternativa para representar problemas específicos.

As funções de ativação foram avaliadas em ambas as arquiteturas (LeNet e RDNet) com os datasets CIFAR-10, MNIST e FashionMNIST. Para cada arquitetura, foram

realizados experimentos com diferentes funções de ativação, buscando determinar o impacto destas na expressividade e eficiência do modelo em cada conjunto de dados.

5.6 Execução e Coleta de Resultados

O treinamento e a avaliação foram realizados em um ambiente python equipado com GPU, utilizando a biblioteca *PyTorch*. Foram realizadas 12 *runs* para cada época de cada função de ativação, com o *seed* variando aleatóriamente entre cada uma. O tempo de execução total foi registrado, e os resultados para cada variação de experimento foram armazenados para análise estatística, incluindo médias e desvios padrão das acurácias.

A implementação completa está disponível em código Python, com modularidade suficiente para permitir replicação ou extensão para outros cenários de análise.

5.7 Validação dos Resultados

A fim de determinar se as diferenças entre os resultados obtidos nas diferentes épocas eram estatisticamente significativas, apliquei o teste t de Student. Este teste comparou o melhor valor obtido em cada época com os demais valores correspondentes, utilizando o *p-value* como critério para significância estatística, considerando um nível de significância de 0,05. A fórmula do teste t utilizada foi:

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}} \tag{5.1}$$

onde:

- t: representa o valor t;
- $\bar{x}_1$ e $\bar{x}_2$: representam as médias das duas amostras;
- s_1 e s_2: representam os desvios padrão das duas amostras;
- n_1 e n_2: representam os tamanhos das duas amostras.

6 RESULTADOS

Neste capítulo, apresento os resultados obtidos a partir dos experimentos realizados, destacando o impacto das diferentes funções de ativação no desempenho e eficiência das redes neurais avaliadas. As análises consideram a acurácia e o tempo de execução em dois cenários experimentais, detalhando os efeitos das funções de ativação em múltiplos *datasets* e configurações.

Inicialmente, os resultados para a arquitetura LeNet-5 são apresentados em tabelas específicas para cada *dataset* (MNIST, FashionMNIST e CIFAR-10), com valores de acurácia calculados a partir dos conjuntos de teste, registrados após 2, 4, 6, 8 e 10 épocas de treinamento, . Essas tabelas permitem avaliar como o desempenho das funções de ativação evolui em estágios iniciais do treinamento.

Em seguida, duas tabelas adicionais demonstram resultados para a arquitetura RDNet-L no dataset CIFAR-10, sintetizando os resultados de acurácia e tempo de execução para as funções de ativação calculados a partir dos conjuntos de teste, em configurações com 5, 10, 15 e 20 épocas de treinamento. Essa análise proporciona uma visão abrangente do compromisso entre precisão e eficiência computacional, evidenciando as forças e limitações de cada função de ativação.

Os resultados são discutidos em relação ao comportamento observado, destacando tendências específicas para cada *dataset* e arquitetura, bem como a influência do aumento do número de épocas sobre a acurácia e o tempo de execução. Essa abordagem busca oferecer *insights* claros sobre a eficácia e viabilidade prática das funções de ativação investigadas. São aplicados testes de validação (teste t de Student) para definir se há significância nos valores apresentados.

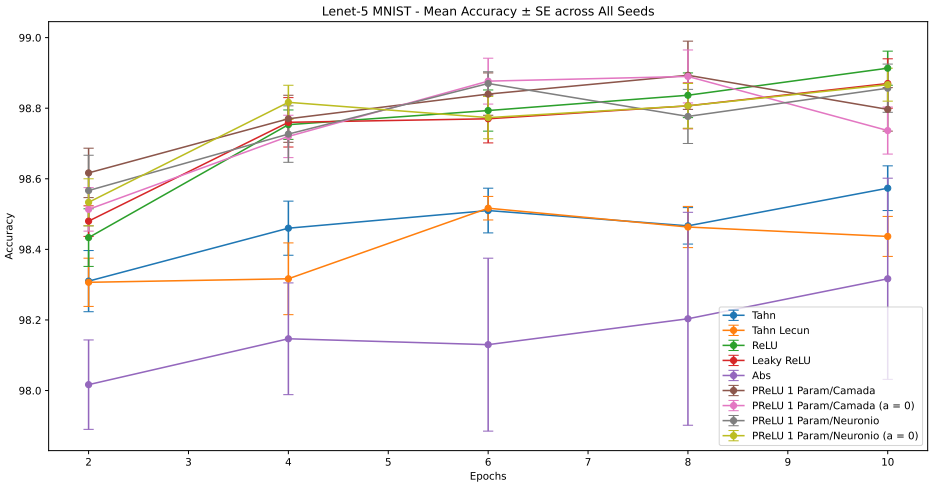
As funções de ativação utilizadas neste estudo incluem: Tangente Hiperbólica (tanh), tanh Lecun, ReLU, Leaky ReLU, Valor Absoluto (Abs), e várias variantes de PReLU, como PRELU-CR (com um parâmetro por camada e inicialização aleatória do **a**), PReLU-NR (com um parâmetro por neurônio e inicialização aleatória do **a**), PRELU-C0 (com um parâmetro por camada e **a** inicializado em 0) e PReLU-N0 (com um parâmetro por neurônio e **a** inicializado em 0).

6.1 Resultados com LeNet-5

Para cada dataset utilizado (MNIST, FashionMNIST e CIFAR-10) com a arquitetura LeNet-5, foram geradas uma tabela e uma figura distintas, demonstrando a evolução da acurácia ao longo das épocas de treinamento. Cada tabela apresenta os valores médios de acurácia para cada época, enquanto as figuras correspondentes visualizam essa progressão.

6.1.1 Resultados com LeNet-5 no Dataset MNIST

Figura 6.1: Médias de Acurácia e Erro Padrão das Funções de Ativação utilizando LeNet-5 no dataset MNIST



Fonte: O Autor

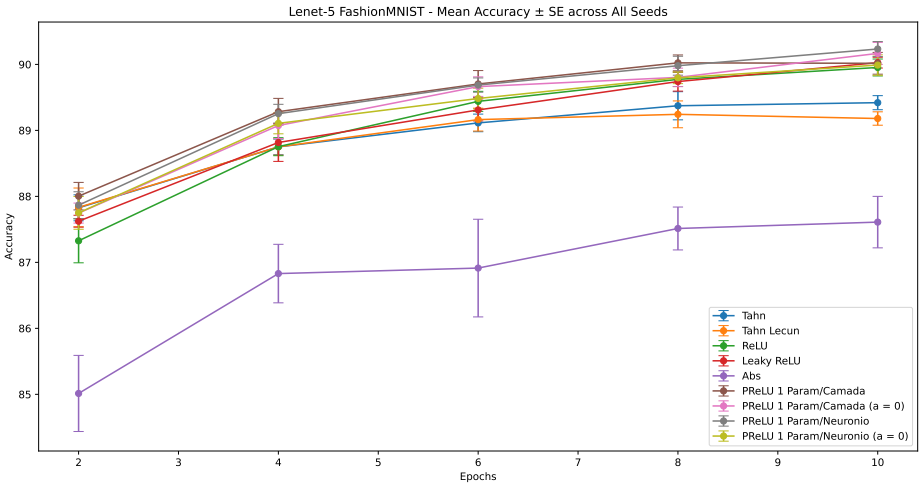
Tabela 6.1: Médias de Acurácia das Funções de Ativação utilizando LeNet-5 no dataset MNIST. Valores em negrito são os melhores por época, enquanto valores em vermelho são estatisticamente diferentes do melhor e em azul são estatisticamente semelhantes ao melhor em cada época. Valores-p são apresentados no Apêndice A.1).

Epochs	2	4	6	8	10
Tanh	98.310	98.460	98.510	98.467	98.573
Tanh Lecun	98.307	98.317	98.517	98.463	98.437
ReLU	98.433	98.753	98.793	98.837	**98.913**
Leaky ReLU	98.480	98.760	98.770	98.807	98.870
Abs	98.017	98.147	98.130	98.203	98.317
PRELU-CR	**98.617**	98.770	98.840	**98.893**	98.797
PReLU-NR	98.567	98.727	98.870	98.777	98.857
PRELU-C0	98.513	98.720	**98.877**	98.890	98.737
PReLU-N0	98.533	**98.817**	98.773	98.807	98.867

Os resultados de acurácia para as diferentes funções de ativação na arquitetura LeNet-5, avaliados no conjunto de teste do MNIST (apresentados na figura 6.1 e na tabela 6.1), indicam que as variantes da PReLU apresentaram os melhores valores de acurácia nas primeiras épocas. No entanto, ao final das 10 épocas de treinamento, a função ReLU se destacou, atingindo 98,913% de acurácia, superando as variantes da PReLU, que não mostraram mais melhorias significativas.

6.1.2 Resultados com LeNet-5 no Dataset FashionMNIST

Figura 6.2: Médias de Acurácia e Erro Padrão das Funções de Ativação utilizando LeNet-5 no dataset FashionMNIST



Fonte: O Autor

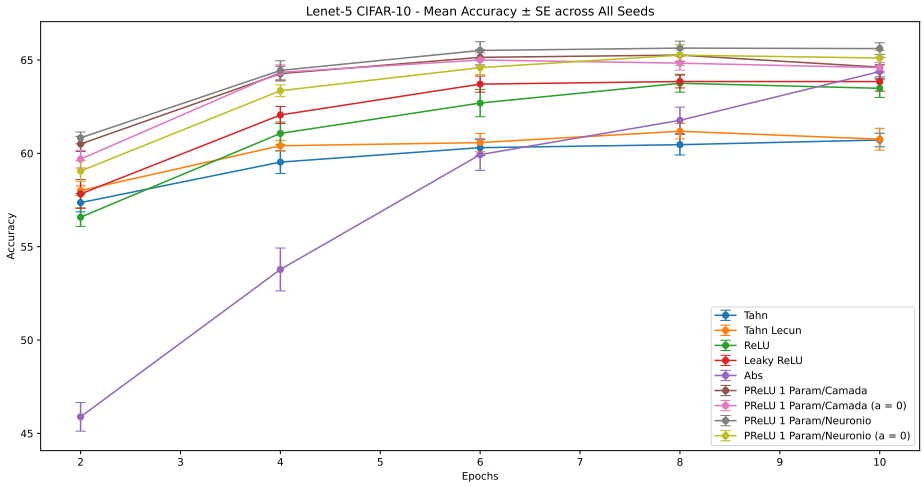
Tabela 6.2: Médias de Acurácia das Funções de Ativação utilizando LeNet-5 no dataset FashionMNIST. Valores em negrito são os melhores por época, enquanto valores em vermelho são estatisticamente diferentes do melhor e em azul são estatisticamente semelhantes ao melhor em cada época. Valores-p são apresentados no Apêndice A.2).

Epochs	2	4	6	8	10
Tanh	87.827	88.750	89.113	89.373	89.420
Tanh Lecun	87.833	88.750	89.163	89.243	89.180
ReLU	87.327	88.753	89.440	89.773	89.953
Leaky ReLU	87.623	88.817	89.310	89.740	90.027
Abs	85.013	86.830	86.913	87.513	87.610
PRELU-CR	**88.003**	**89.283**	**89.703**	**90.023**	90.017
PReLU-NR	87.867	89.253	89.687	89.980	**90.233**
PRELU-C0	87.747	89.073	89.663	89.803	90.167
PReLU-N0	87.750	89.107	89.483	89.797	89.990

Os resultados de acurácia para as diferentes funções de ativação na arquitetura LeNet-5, avaliados no conjunto de teste do FashionMNIST (apresentados na figura 6.2 e na tabela 6.2), indicam que as variantes da PReLU com inicialização aleatória apresentaram os melhores valores de acurácia. Inicialmente, a PReLU com 1 parâmetro por camada obteve os melhores resultados, porém, com o aumento do número de épocas, a PReLU com 1 parâmetro por neurônio foi a que mais se destacou.

6.1.3 Resultados com LeNet-5 no Dataset CIFAR

Figura 6.3: Médias de Acurácia e Erro Padrão das Funções de Ativação utilizando LeNet-5 no dataset CIFAR-10



Fonte: O Autor

Tabela 6.3: Médias de Acurácia das Funções de Ativação utilizando LeNet-5 no dataset CIFAR-10. Valores em negrito são os melhores por época, enquanto valores em vermelho são estatisticamente diferentes do melhor e em azul são estatisticamente semelhantes ao melhor em cada época. Valores-p são apresentados no Apêndice A.3).

Epochs	2	4	6	8	10
Tanh	57.360	59.530	60.303	60.463	60.713
Tanh Lecun	58.007	60.407	60.573	61.183	60.757
ReLU	56.580	61.067	62.693	63.753	63.483
Leaky ReLU	57.827	62.053	63.707	63.847	63.843
Abs	45.887	53.780	59.930	61.767	64.380
PRELU-CR	60.500	64.270	65.140	65.263	64.617
PReLU-NR	**60.830**	**64.440**	**65.510**	**65.637**	**65.610**
PRELU-C0	59.690	64.340	65.000	64.830	64.590
PReLU-N0	59.053	63.353	64.590	65.260	65.107

Os resultados de acurácia para as diferentes funções de ativação na arquitetura LeNet-5, avaliados no conjunto de teste do CIFAR-10 (apresentados na figura 6.3 e na tabela 6.3), indicam que a variante PReLU com um parâmetro por neurônio e inicialização aleatória (PReLU-NR) apresentou o melhor desempenho, superando as demais funções de ativação.

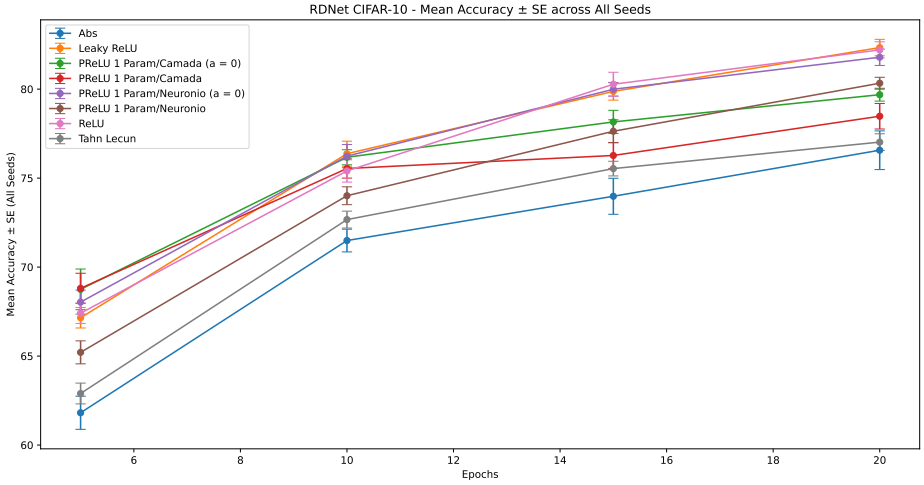
6.2 Análise Geral da LeNet-5

Ao analisar os resultados obtidos com a arquitetura LeNet-5, observou-se que a utilização da função de ativação PReLU, com um parâmetro por neurônio e inicialização aleatória, demonstrou desempenho estatisticamente superior na maioria dos cenários avaliados. Nos casos em que a acurácia alcançada pela PReLU não representou o valor máximo absoluto, a análise estatística não permitiu estabelecer diferenças significativas entre seu desempenho e o da configuração que obteve a maior acurácia.

6.3 Resultados com RDNet-L

Para a arquitetura RDNet-L aplicada ao CIFAR-10, foram geradas duas tabelas e uma figura distintas. Uma tabela apresenta os valores médios de acurácia por época, e a outra, as médias de tempo de execução para cada função de ativação. A figura correspondente visualiza a progressão das médias de acurácia ao longo das épocas.

Figura 6.4: Médias de Acurácia e Erro Padrão das Funções de Ativação utilizando RDNet-L no dataset CIFAR-10



Fonte: O Autor

Tabela 6.4: Médias de Acurácia das Funções de Ativação utilizando RDNet-L no dataset CIFAR-10. Valores em negrito são os melhores por época, enquanto valores em vermelho são estatisticamente diferentes do melhor e em azul são estatisticamente semelhantes ao melhor em cada época. Valores-p são apresentados no Apêndice A.4).

Activation Function	5 Epochs	10 Epochs	15 Epochs	20 Epochs
Tanh	65.1750	73.0400	76.0200	77.1675
Tanh Lecun	62.9650	71.7075	75.1950	77.0225
ReLU	67.4100	76.5400	**80.2750**	82.2050
Leaky ReLU	67.1525	76.3000	79.8725	**82.3350**
Abs	61.8150	70.5925	73.9800	76.5675
PReLU-CR	**68.8075**	75.1350	76.2725	78.4775
PReLU-NR	65.2100	73.3075	77.6325	80.3325
PReLU-C0	68.7500	76.2975	78.1575	79.6875
PReLU-N0	68.0325	**77.2750**	79.9925	81.7925

Tabela 6.5: Médias de Runtimes das Funções de Ativação utilizando RDNet-L no dataset CIFAR-10

Activation Function	5 Epochs	10 Epochs	15 Epochs	20 Epochs
Tahn	**1270.6375**	3870.1450	7565.8550	9842.8275
Tahn Lecun	2273.2775	6035.2775	6806.0575	8165.0225
ReLU	1359.4300	2685.5425	4019.6425	5386.6125
Leaky ReLU	1387.5300	2728.7775	4039.4725	5697.1275
Abs	1574.1700	2914.0300	4377.8725	5808.6550
PReLU-CR	1573.9875	3191.6925	4914.8900	6214.5600
PReLU-NR	2045.4875	**2422.0250**	**3865.6600**	6018.0875
PReLU-C0	1591.7050	3190.4775	4706.8175	6368.9175
PReLU-N0	1512.0200	3209.0275	4390.9425	**4799.8450**

Os resultados de acurácia obtidos para as diferentes funções de ativação na arquitetura RDNet-L, avaliados no conjunto de teste do CIFAR-10 (apresentados na figura 6.4 e na tabela 6.4), indicam que no último conjunto de épocas não há diferenças significativas entre os valores de acurácia da PReLU com um parâmetro por neurônio e *"a"* iniciado em 0 com as variantes da ReLU, estes que se sobressaíram em relação aos demais. Entretanto, a PReLU com um parâmetro por neurônio e *"a"* iniciado em 0 demonstrou ser a função de ativação mais *sample-efficient*, apresentando, nas primeiras épocas, os melhores resultados ou desempenhos tão próximos do melhor que não havia diferenciação estatística. Além disso, de acordo com os resultados presentes na tabela 6.5, aparenta haver uma tendência de que a PReLU com um parâmetro por neurônio possua tempos de execução menores; contudo, a ausência de uma análise estatística impede a validação formal dessa diferença.

7 CONCLUSÃO

Este trabalho investigou o impacto da função de ativação PReLU em redes neurais aplicadas a problemas de classificação de imagens. A hipótese inicial era de que a PReLU poderia oferecer vantagens tanto em termos de desempenho quanto de eficiência computacional em comparação com a ReLU, especialmente ao lidar com problemas de maior complexidade.

A partir dos resultados obtidos pode-se concluir que, predominantemente, a variante da PReLU com os maiores valores de acurácia foi com 1 parâmetro por neurônio e ativação padrão. No caso da LeNet, essa variante demonstrou ser particularmente eficaz ao lidar com o aumento da complexidade dos *datasets*, superando ou se equiparando às demais funções de ativação em todos os experimentos realizados com a arquitetura. A superioridade da PReLU tornou-se mais evidente à medida que a complexidade dos dados cresceu. Porém no caso da RDNet aplicada no CIFAR-10, que é uma rede mais complexa que a LeNet, onde um número de épocas mais elevado se provou mais benéfico para a acurácia, não houve variações estatisticamente signinicantes para definir qual a função que apresenta melhores valores de acurácia, podendo ser a ReLU, a Leaky ReLU ou a PReLU com um parâmetro por neurônio e a iniciado com valor zero, embora seja evidente que a PReLU com um parâmetro por neurônio seja a função mais *sample efficient*.

Os resultados obtidos indicam que a escolha da função de ativação exerce impacto substancial sobre o desempenho de redes neurais com arquiteturas menos complexas, como a LeNet. Nesta, a configuração da PReLU com um parâmetro por neurônio e inicialização aleatória apresentou desempenho superior em termos de acurácia, especialmente em conjuntos de dados de maior complexidade. Em contrapartida, na arquitetura RDNet-L, caracterizada por maior complexidade, embora a análise estatística não tenha demonstrado diferenças significativas entre as funções de ativação ReLU e PReLU (e suas respectivas variantes) quanto à acurácia final, observou-se que a PReLU com um parâmetro por neurônio exibiu maior *sample efficiency*, sugerindo um aprendizado mais eficaz com menor quantidade de dados ou épocas.

7.1 Limitações e Ameaças à Validade

Este estudo apresenta algumas limitações que podem afetar a generalização dos resultados obtidos:

Escopo restrito aos *datasets* de identificação de imagens: O estudo foi realizado com *datasets* comummente utilizados em tarefas de identificação de imagens, como MNIST, FashionMNIST e CIFAR-10. Embora esses *datasets* sejam representativos em termos de imagens rotuladas para classificação, eles são relativamente simples e podem não refletir a complexidade de problemas mais desafiadores no mundo real. Como resultado, a escolha desses *datasets* pode limitar a generalização dos resultados, uma vez que funções de ativação que se destacam nesses conjuntos podem não apresentar o mesmo desempenho em *dataset*s mais complexos ou em tarefas de classificação de imagens mais sofisticadas.

Ausência de funções de ativação em modelos mais avançados: Este estudo não investigou funções de ativação em modelos mais complexos, como o *Vision Transformer* (ViT), que lidera o *leaderboard* (IMAGE...,) de melhores valores de acurácia para CIFAR-10. Embora modelos como o ViT sejam conhecidos por fornecerem resultados superiores em relação à acurácia de modelos, eles exigem maior capacidade computacional e conjuntos de dados de treinamento significativamente maiores. A ausência de uma avaliação dessas funções de ativação em arquiteturas mais avançadas pode ser considerada uma limitação importante, pois pode haver diferenças significativas no desempenho das funções quando aplicadas a redes neurais mais sofisticadas, o que poderia ampliar a compreensão sobre sua aplicabilidade em diferentes tipos de modelos.

Discrepâncias nos Tempos de Execução: Uma das questões levantadas durante o estudo foi o tempo de execução das funções de ativação. Funções como *abs*, *ReLU*, e *tanh* apresentaram tempos de execução superiores à *PReLU*, o que gerou questionamentos sobre a validade desses resultados. Em um contexto teórico, a *ReLU* seria mais eficiente devido à sua simplicidade, mas a inclusão do parâmetro a na *PReLU* poderia gerar cálculos adicionais durante o treinamento, o que poderia impactar os tempos de execução. Essa discrepância pode ser atribuída a fatores como a implementação das funções nas bibliotecas utilizadas, otimizações específicas de hardware, ou configurações do sistema. Futuros estudos devem investigar mais a fundo esses fatores, para garantir que os tempos de execução observados são consistentes em diferentes ambientes e configurações.

7.2 Trabalhos Futuros

A fim de superar as limitações identificadas neste estudo, algumas direções de pesquisa podem ser exploradas em trabalhos futuros:

Exploração de conjuntos de dados mais complexos: Embora este estudo tenha se concentrado em *datasets* amplamente utilizados e relativamente simples como MNIST, FashionMNIST e CIFAR-10, futuros estudos poderiam expandir a análise para datasets mais desafiadores e complexos, como ImageNet ou ADE20K. Isso permitiria avaliar a eficácia das funções de ativação em contextos mais próximos dos problemas do mundo real, com imagens de maior variação e complexidade. Além disso, a utilização de *datasets* mais complexos possibilitaria uma comparação mais abrangente do desempenho das funções de ativação em redes neurais que lidam com tarefas mais difíceis e diversificadas.

Avaliação de funções de ativação em modelos mais avançados: Outro aspecto importante seria a inclusão de funções de ativação em modelos mais avançados, como o *Vision Transformer* (ViT), que tem se mostrado promissor em tarefas de visão computacional, embora exija maior capacidade computacional e conjuntos de dados mais amplos para treinamento. A avaliação das funções de ativação nesses modelos proporcionaria uma visão mais completa sobre sua aplicabilidade e desempenho, ajudando a entender como elas se comportam em arquiteturas mais complexas e com maior demanda de dados. Isso também permitiria identificar como as funções de ativação podem ser otimizadas para redes mais sofisticadas, potencialmente abrindo novas perspectivas para sua utilização em modelos de ponta.

Impacto da PReLU na Complexidade Computacional: Uma questão que poderia ser investigada é o impacto da *PReLU* na simplificação das arquiteturas. Apesar de a *PReLU* adicionar um parâmetro adicional a por neurônio, isso pode permitir que a rede resolva problemas complexos com menos neurônios ou camadas, mantendo ou até melhorando a acurácia. Investigar essa possibilidade seria útil para o desenvolvimento de redes mais compactas e eficientes, que gerem menos processamento, sem comprometer o desempenho. Adicionalmente, a análise do impacto da complexidade da *PReLU*, em termos do número de parâmetros adicionais, também é uma direção interessante. Embora a *PReLU* tenha a vantagem de maior expressividade, o aumento do número de parâmetros pode resultar em maiores tempos de treinamento e maior consumo de memória. Estudos futuros poderiam explorar de que maneira otimizar o número de parâmetros ou ajustar a *PReLU* para reduzir o impacto computacional sem perder desempenho.

REFERÊNCIAS

AGARAP, A. F. M. Deep Learning using Rectified Linear Units (ReLU). February 7 2019.

BERNGARDT, O. I. Improving Classification Neural Networks by using Absolute activation function (MNIST/LeNET-5 example). April 25 2023.

HE, K. et al. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification. p. 1026–1034, 2015.

IMAGE Classification on CIFAR-10. <https://paperswithcode.com/sota/image-classification-on-cifar-10>. Acessado em: 27-11-2024. Available from Internet: <https://paperswithcode.com/sota/image-classification-on-cifar-10>.

KIM, D.; HEO, B.; HAN, D. Densenets reloaded: Paradigm shift beyond resnets and vits. August 7 2024.

KRIZHEVSKY, A.; HINTON, G. E. Learning multiple layers of features from tiny images. 2009.

KUNC, V.; KLéMA, J. Three decades of activations: A comprehensive survey of 400 activation functions for neural networks. **arXiv preprint arXiv:2402.09092**, 2024.

LECUN, Y. Generalization and network design strategies. 1989.

LECUN, Y. et al. Backpropagation applied to handwritten zip code recognition. **Neural Computation**, MIT Press, v. 1, n. 4, p. 541–551, 1989.

LECUN, Y. et al. Gradient-based learning applied to document recognition. **Proceedings of the IEEE**, IEEE, v. 86, n. 11, p. 2278–2324, 1998.

LECUN, Y. et al. Learning algorithms for classification: A comparison on handwritten digit recognition. **Unspecified**, 1995.

MAAS, A. L.; HANNUN, A. Y.; NG, A. Y. Rectifier nonlinearities improve neural network acoustic models. Atlanta, GA, v. 30, p. 3, 2013.

MINSKY, M. L.; PAPERT, S. A. **Perceptrons: An Introduction to Computational Geometry**. Expanded edition. [S.l.]: MIT press, 1988.

NAIR, V.; HINTON, G. E. **Rectified Linear Units Improve Restricted Boltzmann Machines**. 2010. 807–814 p.

PINTO, R. C.; TAVARES, A. R. PReLU: Yet Another Single-Layer Solution to the XOR Problem. September 18 2024.

RAMACHANDRAN, P.; ZOPH, B.; LE, Q. V. Searching for activation functions. **arXiv preprint arXiv:1710.05941v2**, 16 Oct 2017. Available from Internet: <https://arxiv.org/abs/1710.05941>.

SHANG, Q. et al. RDNet: A Reinforced-Deformable Convolutional Network for Crowd Counting. In: **Proceedings of the 2022 IEEE International Conference on Robotics and Biomimetics**. [S.l.]: IEEE, 2022. p. December 5–9.

XIAO, H.; RASUL, K.; VOLLGRAF, R. Fashion-mnist: A novel image dataset for benchmarking machine learning algorithms. **arXiv preprint arXiv:1708.07747**, 2017.

APÊNDICE A — VALORES-P DOS TESTES T DE STUDENT

A.1 Testes t de Student com LeNet-5 no MNIST

- **Testes em 2 Épocas**

  Comparações Estatisticamente Diferentes à PReLU-CR:

  Tanh (*p-value*: 0.0006505712); Tanh Lecun (*p-value*: 0.0002138155); Abs (*p-value*: 0.0000230032); ReLU (*p-value*: 0.0135227893); Leaky ReLU (*p-value*: 0.0165901063).

  Comparações Estatisticamente Similares à PReLU-CR:

  PReLU-NR (*p-value*: 0.4941082502); PRELU-C0 (*p-value*: 0.0855379048); PReLU-N0 (*p-value*: 0.1699969876).

- **Testes em 4 Épocas**

  Comparações Estatisticamente Diferentes à PReLU-N0:

  Tanh (*p-value*: 0.0000336603); Tanh Lecun (*p-value*: 0.0000131461); Abs (*p-value*: 0.0000246845).

  Comparações Estatisticamente Similares à PReLU-N0:

  PRELU-CR (*p-value*: 0.3477445359); PReLU-NR (*p-value*: 0.1340095733); PRELU-C0 (*p-value*: 0.0546701279); ReLU (*p-value*: 0.1205048990); Leaky ReLU (*p-value*: 0.2741089854)

- **Testes em 6 Épocas**

  Comparações Estatisticamente Diferentes à PReLU-C0:

  Tanh (*p-value*: 0.0000260193); Tanh Lecun (*p-value*: 0.0000038353); Abs (*p-value*: 0.0004165711).

  Comparações Estatisticamente Similares à PReLU-C0:

  PRELU-CR (*p-value*: 0.5215583497); PReLU-NR (*p-value*: 0.8833822499); PReLU-N0 (*p-value*: 0.0717265331); ReLU (*p-value*: 0.1477466146); Leaky ReLU (*p-value*: 0.0932482561)

- **Testes em 8 Épocas**

  Comparações Estatisticamente Diferentes à PReLU-CR:

  Tanh (*p-value*: 0.0000322079); Tanh Lecun (*p-value*: 0.0000437334); Abs (*p-value*: 0.0033022175).

  Comparações Estatisticamente Similares à PReLU-CR:

  PReLU-NR (*p-value*: 0.1331638349); PRELU-C0 (*p-value*: 0.9632166556); PReLU-

N0 (*p-value*: 0.2354600341); ReLU (*p-value*: 0.4142066083); Leaky ReLU (*p-value*: 0.2381731356)

- **Testes em 10 Épocas**

  Comparações Estatisticamente Diferentes à ReLU:

  Tanh (*p-value*: 0.0000146122); Tanh Lecun (*p-value*: 0.0000006478); Abs (*p-value*: 0.0043914252); PRELU-CR (*p-value*: 0.0276271389); PRELU-C0 (*p-value*: 0.0039593073).

  Comparações Estatisticamente Similares à ReLU:

  PReLU-NR (*p-value*: 0.2838337778); PReLU-N0 (*p-value*: 0.2621253071); Leaky ReLU (*p-value*: 0.4074081252).

A.2 Testes t de Student com LeNet-5 no FashionMNIST

- **Testes em 2 Épocas**

  Comparações Estatisticamente Diferentes à PReLU-CR:

  Abs (*p-value*: 0.0000044545); ReLU (*p-value*: 0.0148214000); Leaky ReLU (*p-value*: 0.0187167740).

  Comparações Estatisticamente Similares à PReLU-CR:

  PReLU-NR (*p-value*: 0.4334425130); PRELU-C0 (*p-value*: 0.1296833865); PReLU-N0 (*p-value*: 0.2088991937); Tanh (*p-value*: 0.3299787833); Tanh Lecun (*p-value*: 0.4437533361).

- **Testes em 4 Épocas**

  Comparações Estatisticamente Diferentes à PReLU-CR:

  Tanh (*p-value*: 0.0023146257); Tanh Lecun (*p-value*: 0.0032786978); Abs (*p-value*: 0.0000032727); ReLU (*p-value*: 0.0044355611); Leaky ReLU (*p-value*: 0.0454943740).

  Comparações Estatisticamente Similares à PReLU-CR:

  PReLU-NR (*p-value*: 0.8372304558); PRELU-C0 (*p-value*: 0.2605235754); PReLU-N0 (*p-value*: 0.2678199939).

- **Testes em 6 Épocas**

  Comparações Estatisticamente Diferentes à PReLU-CR:

  Tanh (*p-value*: 0.0020069802); Tanh Lecun (*p-value*: 0.0051712973); Abs (*p-value*: 0.0000602904); Leaky ReLU (*p-value*: 0.0297203100).

Comparações Estatisticamente Similares à PReLU-CR:

PReLU-NR (*p-value*: 0.9027903260); PRELU-C0 (*p-value*: 0.7882531042); PReLU-N0 (*p-value*: 0.1659074468); ReLU (*p-value*: 0.1091420511).

- **Testes em 8 Épocas**

  Comparações Estatisticamente Diferentes à PReLU-CR:

  Tanh (*p-value*: 0.0008002187); Tanh Lecun (*p-value*: 0.0001428500); Abs (*p-value*: 0.0000000755); Leaky ReLU (*p-value*: 0.0279793323); ReLU (*p-value*: 0.0224997753); PReLU-N0 (*p-value*: 0.0238994492).

  Comparações Estatisticamente Similares à PReLU-CR:

  PReLU-NR (*p-value*: 0.7102521695); PRELU-C0 (*p-value*: 0.0716988598).

- **Testes em 10 Épocas**

  Comparações Estatisticamente Diferentes à PReLU-NR:

  Tanh (*p-value*: 0.0000022253); Tanh Lecun (*p-value*: 0.0000001725); Abs (*p-value*: 0.0000002479); Leaky ReLU (*p-value*: 0.0268862299); ReLU (*p-value*: 0.0183833050).

  Comparações Estatisticamente Similares à PReLU-NR:

  PRELU-CR (*p-value*: 0.1112893157); PRELU-C0 (*p-value*: 0.5873839503); PReLU-N0 (*p-value*: 0.0681433348).

A.3 Testes t de Student com LeNet-5 no CIFAR-10

- **Testes em 2 Épocas**

  Comparações Estatisticamente Diferentes à PReLU-NR:

  Tanh (*p-value*: 0.0000006727); Tanh Lecun (*p-value*: 0.0000654183); Abs (*p-value*: 0.0000000001); Leaky ReLU (*p-value*: 0.0000001079); ReLU (*p-value*: 0.0000001080); PRELU-C0 (*p-value*: 0.0061861408); PReLU-N0 (*p-value*: 0.0006583605)

  Comparações Estatisticamente Similares à PReLU-NR:

  PRELU-CR (*p-value*: 0.3095775733).

- **Testes em 4 Épocas**

  Comparações Estatisticamente Diferentes à PReLU-NR:

  Tanh (*p-value*: 0.0000006648); Tanh Lecun (*p-value*: 0.0000001684); Abs (*p-value*: 0.0000000185); Leaky ReLU (*p-value*: 0.0001091898); ReLU (*p-value*: 0.0000348860); PReLU-N0 (*p-value*: 0.0113863784)

Comparações Estatisticamente Similares à PReLU-NR:

PRELU-CR (*p-value*: 0.6608935169); PRELU-C0 (*p-value*: 0.8001789740).

- **Testes em 6 Épocas**

  Comparações Estatisticamente Diferentes à PReLU-NR:

  Tanh (*p-value*: 0.0000000369); Tanh Lecun (*p-value*: 0.0000001004); Abs (*p-value*: 0.0000010469); Leaky ReLU (*p-value*: 0.0008021519); ReLU (*p-value*: 0.0002371695); PReLU-N0 (*p-value*: 0.0330150899)

  Comparações Estatisticamente Similares à PReLU-NR:

  PRELU-CR (*p-value*: 0.3341473638); PRELU-C0 (*p-value*: 0.2007988075).

- **Testes em 8 Épocas**

  Comparações Estatisticamente Diferentes à PReLU-NR:

  Tanh (*p-value*: 0.0000000387); Tanh Lecun (*p-value*: 0.0000000271); Abs (*p-value*: 0.0000048862); Leaky ReLU (*p-value*: 0.0000917539); ReLU (*p-value*: 0.0002615388); PRELU-C0 (*p-value*: 0.0227713904)

  Comparações Estatisticamente Similares à PReLU-NR:

  PRELU-CR (*p-value*: 0.2230765928); PReLU-N0 (*p-value*: 0.3595844832).

- **Testes em 10 Épocas**

  Comparações Estatisticamente Diferentes à PReLU-NR:

  Tanh (*p-value*: 0.0000000027); Tanh Lecun (*p-value*: 0.0000001111); Abs (*p-value*: 0.0021899038); Leaky ReLU (*p-value*: 0.0004504252); ReLU (*p-value*: 0.0000837852); PRELU-C0 (*p-value*: 0.0018667921); PRELU-CR (*p-value*: 0.0179307224).

  Comparações Estatisticamente Similares à PReLU-NR:

  PReLU-N0 (*p-value*: 0.1319770205).

A.4 Testes t de Student com LeNet-5 no CIFAR-10

- **Testes em 5 Épocas**

  Comparações Estatisticamente Diferentes à PRELU-CR:

  Tanh (*p-value*: 0.0000060450); Tanh Lecun (*p-value*: 0.0000000623); Abs (*p-value*: 0.0000001161); PReLU-NR (*p-value*: 0.0001146094); ReLU (*p-value*: 0.0059572791); Leaky ReLU (*p-value*: 0.0027484785).

  Comparações Estatisticamente Similares à PRELU-CR:

  PReLU-N0 (*p-value*: 0.1140680658); PRELU-C0 (*p-value*: 0.9327135433).

- **Testes em 10 Épocas**

  Comparações Estatisticamente Diferentes à PReLU-N0:

  Tanh (*p-value*: 0.0000000012); Tanh Lecun (*p-value*: 0.0000000016); Abs (*p-value*: 0.0000000014); PReLU-NR (*p-value*: 0.0000000631); PRELU-CR (*p-value*: 0.0000196562); PRELU-C0 (*p-value*: 0.0170175759), Leaky ReLU (*p-value*: 0.0246918963).

  Comparações Estatisticamente Similares à PReLU-N0:

  ReLU (*p-value*: 0.0678383425);

- **Testes em 15 Épocas (Épocas Finais**

  Comparações Estatisticamente Diferentes à ReLU:

  Tanh (*p-value*: 0.0000002206); Tanh Lecun (*p-value*: 0.0000000264); Abs (*p-value*: 0.0000002332); PReLU-NR (*p-value*: 0.0002779623); PRELU-CR (*p-value*: 0.0000077901); PRELU-C0 (*p-value*: 0.0018185065).

  Comparações Estatisticamente Similares à ReLU:

  PReLU-N0 (*p-value*: 0.7734255557); Leaky ReLU (*p-value*: 0.9681922353).

- **Testes em 20 Épocas (Épocas Finais)**

  Comparações Estatisticamente Diferentes à Leaky ReLU:

  Tanh (*p-value*: 0.0000000016); Tanh Lecun (*p-value*: 0.0000000023); Abs (*p-value*: 0.0000004193); PReLU-NR (*p-value*: 0.0000097777); PRELU-CR (*p-value*: 0.0000009175); PRELU-C0 (*p-value*: 0.0000009685).

  Comparações Estatisticamente Similares à Leaky ReLU:

  PReLU-N0 (*p-value*: 0.1115335161); ReLU (*p-value*: 0.6517017691).